

ReplyFlow | 高风险售后 Agent 评测与人机协同工作台

一个搭载在电商邮件系统顶部聚合站内信上的 AI 回复能力原型：低风险更快处理，中风险人工确认，高风险发送前拦截。

演示边界：邮件、订单、物流、发送和 ROI 均为虚构或本地模拟；不连接真实 Amazon、邮箱、支付或订单写入接口。Coze 只负责 Analyze/Draft，本地控制层负责事实、风险、状态、确认、幂等和审计。

01 | 产品定位

ReplyFlow 保留原客服邮件工作台，在顶部聚合站内信上增量接入单 Agent。右下角模拟邮件台可输入一行邮件、选择虚构订单并真实改变本地 SQLite 状态。

02 | 处理链路

模拟接入 → 原始收件箱 → 顶部聚合站内信 → Coze Analyze/Draft → 本地事实与风险网关 → L1 自动发送 / L2 草稿确认 / L3 高风险核对 → 本地模拟 outbox。

03 | 架构取舍

Coze 用于快速编排模型分析和草稿生成；自建控制层负责 8 个 MCP Tools、3 个 Skills、订单/物流事实、只读回复依据、R0 - R3 风险、L1 - L3 状态机、确认、幂等和审计。

04 | 评测证据

指标	结果	解释
离线案例	30 (R2: 13)	Demo 评测集，含高风险切片
动态接入率	100% (29/29)	模拟邮件能进入聚合流程
Demo / Interactive 未授权承诺	0 / 1	Demo 通过；Interactive 复测发现 1 条
无依据订单事实违规	0	事实来自本地 Tool/依据层
Demo / Interactive 高风险召回	61.5% (8/13)	两种模式均未达安全门槛，自动决策 No-Go
Interactive 结构校验	26/30	4 条 Coze 输出未通过本地 Schema 校验

05 | 边界与限制

2026-09-03 Interactive 复测时 Coze 额度可用，30 条案例完成评测；高风险召回 61.5% (8/13)、意图准确率 64.3% (18/28)，出现 1 条未授权承诺和 4 条结构校验失败，因此仍为 No-Go。项目不连接真实 Amazon、邮箱、支付或订单接口，不包含主管/审批、多 Agent、政策治理等扩展范围。ROI 仅为虚构敏感性分析，不代表真实收益。

运行：.venv\Scripts\python.exe stage_b_server.py --port 8511 · http://127.0.0.1:8511/